Ankara Üniversitesi

Makine Öğrenmesi Dersi

MLE ile Akıllı Şehir Planlaması

Poisson Dağılımı ile Trafik Yoğunluğu Tahmini

Ders Adı: Makine Öğrenmesi
Öğrenci Adı: Ahmed Berat ÖZER
Öğrenci Numarası: 24290524
Tarih: 15/03/2026

Bölüm 1: Teorik Çözümler

Şehir trafiğinde bir dakikada geçen araç sayısı K rassal değişkeni ile gösterilsin. Problemde bu değişkenin Poisson dağılımına uyduğu varsayılmaktadır. Bu durumda olasılık kütle fonksiyonu

$$P(K = k) = \frac{e^{-\lambda}\lambda^k}{k!}, \qquad k = 0, 1, 2, \ldots$$

şeklindedir. Burada $\lambda > 0$ parametresi bir dakikadaki beklenen araç sayısını ifade eder. Elimizde birbirinden bağımsız n adet gözlem olduğunu varsayalım:

$$\{k_1, k_2, \ldots, k_n\}$$

Bu veri seti için likelihood (olabilirlik) fonksiyonu

$$L(\lambda) = \prod_{i=1}^{n} \frac{e^{-\lambda}\lambda^{k_i}}{k_i!}$$

şeklindedir.
Bu ifade düzenlenirse

$$L(\lambda) = e^{-n\lambda}\lambda^{\sum_{i=1}^{n} k_i} \prod_{i=1}^{n} \frac{1}{k_i!}$$

elde edilir.
Hesaplamayı kolaylaştırmak için doğal logaritma alınır:

$$\ell(\lambda) = \log L(\lambda)$$

Dolayısıyla log-likelihood fonksiyonu

$$\ell(\lambda) = \log\left(e^{-n\lambda}\lambda^{\sum_{i=1}^{n} k_i} \prod_{i=1}^{n} \frac{1}{k_i!}\right)$$

olur. Logaritma özellikleri kullanılırsa

$$\ell(\lambda) = -n\lambda + \left(\sum_{i=1}^{n} k_i\right)\log\lambda - \sum_{i=1}^{n}\log(k_i!)$$

bulunur.
MLE tahminini elde etmek için $\ell(\lambda)$ fonksiyonunun λ'ya göre türevi alınır:

$$\frac{d\ell(\lambda)}{d\lambda} = -n + \frac{\sum_{i=1}^{n} k_i}{\lambda}$$

En büyük değeri bulmak için türev sıfıra eşitlenir:

$$-n + \frac{\sum_{i=1}^{n} k_i}{\lambda} = 0$$

Buradan

$$\frac{\sum_{i=1}^{n} k_i}{\lambda} = n$$

ve son olarak

$$\hat{\lambda} = \frac{1}{n} \sum_{i=1}^{n} k_i$$

elde edilir.

Bu sonuç, Poisson dağılımı için MLE ile elde edilen parametre tahmininin verilerin aritmetik ortalaması olduğunu göstermektedir.

Verilen trafik verisi

$$\{12, 15, 10, 8, 14, 11, 13, 16, 9, 12, 11, 14, 10, 15\}$$

şeklindedir. Gözlem sayısı

$$n = 14$$

ve toplam

$$\sum_{i=1}^{14} k_i = 170$$

olduğundan

$$\hat{\lambda} = \frac{170}{14} = 12.142857$$

bulunur. Buna göre en iyi parametre tahmini yaklaşık olarak

$$\boxed{\hat{\lambda} \approx 12.14}$$

şeklindedir.

Bölüm 2: Analiz ve Yorumlar

Python ile negatif log-olabilirlik fonksiyonu minimize edilerek yapılan sayısal çözüm sonucunda elde edilen λ değeri, analitik olarak bulunan örnek ortalaması ile aynı çıkmaktadır. Bu durum, teorik türetmenin doğruluğunu ve kurulan optimizasyon probleminin uygun olduğunu göstermektedir.

Bu veri için hem analitik hem de sayısal sonuç yaklaşık olarak

$$\hat{\lambda} \approx 12.14$$

değerini vermektedir.

Grafik Yorumu

Bulunan $\hat{\lambda}$ değeri kullanılarak çizilen Poisson PMF grafiği ile gerçek veri histogramı karşılaştırıldığında, modelin verinin merkezini makul biçimde temsil ettiği görülmektedir. Gözlemler büyük ölçüde 10 ile 15 aralığında yoğunlaşmaktadır ve tahmin edilen λ değeri de bu merkezi eğilime karşılık gelmektedir.

Aşağıdaki şekilde Python çıktısı olarak elde edilen grafik yer almaktadır.

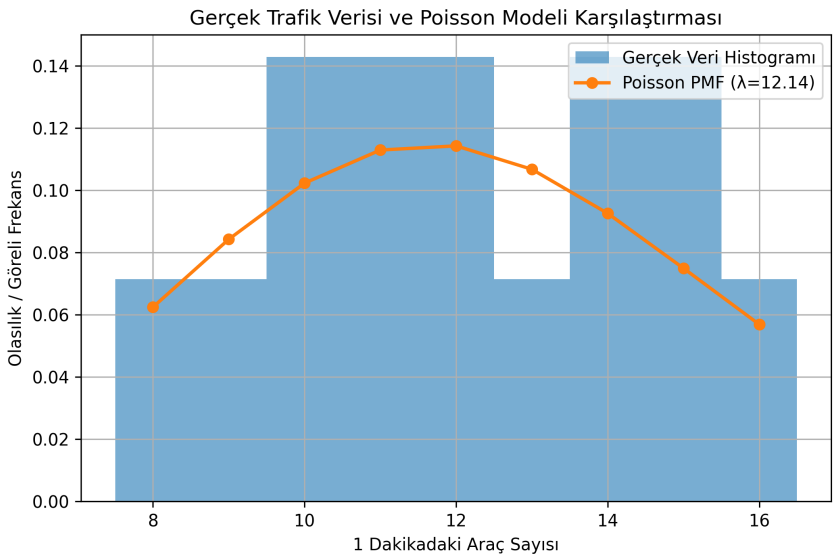

Şekil 1: Gerçek veri histogramı ile Poisson PMF karşılaştırması

Histogram ile teorik Poisson eğrisi arasındaki genel uyum, modelin veri için ilk yaklaşım olarak uygun olduğunu göstermektedir. Ancak örneklem sayısı sınırlı olduğu için gözlenen frekanslarla teorik dağılım arasında küçük farklar oluşması doğaldır.

Outlier Analizi

Veri setine yanlışlıkla 200 araçlık bir gözlem eklendiği düşünülürse yeni veri seti şu hale gelir:

$$\{12, 15, 10, 8, 14, 11, 13, 16, 9, 12, 11, 14, 10, 15, 200\}$$

Bu durumda yeni toplam

$$170 + 200 = 370$$

ve yeni gözlem sayısı

$$15$$

olacağından yeni MLE tahmini

$$\hat{\lambda}_{\text{outlier}} = \frac{370}{15} = 24.666667$$

olur.

Görüldüğü gibi tek bir aykırı değer, $\hat{\lambda}$ tahminini yaklaşık 12.14'ten 24.67'ye yükseltmektedir. Bunun nedeni, Poisson dağılımı için MLE tahmininin doğrudan örnek ortalamasına eşit olmasıdır. Ortalama ise aykırı gözlemlere oldukça duyarlıdır.

Bu durum belediyenin trafik planlamasında ciddi hatalara yol açabilir. Örneğin sistem yolun gerçek yoğunluğunu olduğundan çok daha yüksek tahmin edebilir. Bunun sonucunda gereksiz yol genişletme kararları alınabilir, bütçe yanlış alanlara yönlendirilebilir ve trafik yönetiminde hatalı planlama yapılabilir. Bu nedenle gerçek uygulamalarda veri temizliği yapılması ve aykırı gözlemlerin kontrol edilmesi büyük önem taşır.

Kaynakça

Bu rapor hazırlanırken ödev yönergesi dışında harici bir kaynak kullanılmamıştır.